

Econometrics

Лекция 1. Общая информация и введение

Линейная регрессия и метод наименьших квадратов, МНК(OLS)

Из Марно Вербника

- $X = x_1, x_2, \dots, x_n$ - вектор параметров с размерностью $(n, 1)$.
- Y - вектор значений с размерностью $(n, 1)$

Вопрос на который отвечает метод наименьших квадратов звучит следующим образом: **Какая линейная комбинация X с константой дает хорошую аппроксимацию для Y ?**

- Для того, что бы ответить на этот вопрос запишем произвольную линейную комбинацию: $\hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_n x_n$, где $\hat{\beta}_n$ - константы, которые мы в будущем подберем.
- Разность между наблюдаемым значением и его линейной аппроксимацией: $y_i - [\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_n x_{in}]$
- Следовательно минимизировать будем функцию квадратов разностей

$$S(\hat{\beta}) = \sum_{i=1}^n (y_i - x_i' \hat{\beta})^2$$

- Отсюда следует, что решениями проблемы минимизации является одно из двух следующих уравнений:

$$b = \left(\sum_{i=1}^n x_i x_i' \right)^{-1} \sum_{i=1}^n x_i y_i$$

$$\beta = (X'X)^{-1}(X'Y)$$

Распределения

$$Z \sim N(0, 1)$$

$$\sum Z_i^2 \sim \chi_n^2$$

$$E(\chi_n^2) = n, \text{Var}(\chi_n^2) = 2n$$

$$\frac{Z}{\sqrt{\frac{\chi_n^2}{n}}} \sim t_n$$

$$E(t_n) = 0, \text{Var}(t_n) = 2n$$

$$\frac{\chi_n^2/n}{\chi_m^2/m} \sim F_{n,m}$$

$$E(F_{n,m}) = \frac{m}{m-2}$$

Лекция 1.2. Повторение ТВ и МС

Функция распределения $F_X(x)$ СВ X называется: $F_X(x) = P(X \leq x)$, СВ X называется непрерывной, если существует функция $f(x)$, такая что $F_X'(x) = f(x)$, где $f(x)$ обладает следующими свойствами:

$$f(x) \geq 0$$

$$\int_{-\infty}^{+\infty} f(x)dx = 1$$

$$P(a \leq x \leq b) = \int_a^b f(x)dx$$

МО для дискретной СВ: $E(X) = \sum_{i=1}^N X_i P_i$, МО для непрерывной СВ: $E(X) = \int_{-\infty}^{+\infty} x f(x) dx$

Дисперсия СВ X: $\sigma^2 = Var(X) = E(X - E(X))^2 = E^2(X) - E(X^2)$, стандартное отклонение - $\sqrt{\sigma^2}$

Ковариация двух СВ X Y $Cov(X, Y) = E[(X - E(X))(Y - E(Y))]$

Коэффициент корреляции $r_{XY} = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$, со следующими свойствами:

1. $|r_{XY}| \leq 1$,
2. При $r_{XY} = 0$ линейная связь СВ X и Y отсутствует полностью,
3. При $r_{XY} = 1$ то между случайными величинами X и Y существует точная линейная связь: $Y = aX + b$

Лекция 2. Линейная регрессия для одного параметра

Линейный регрессионный анализ объединяет широкий круг задач, связанных с построением зависимостей между двумя переменными: X и Y. X – независимая, объясняющая, экзогенная переменная, регрессор, regressor, Y- зависимая, объясняемая, эндогенная переменная, regressand.

$E(Y|X = x) = f(x)$ – уравнение парной регрессии, из которого следует следующее: $Y_i = E(Y|X = x_i) + \epsilon_i = f(X_i) + \epsilon_i$, где ϵ стохастическое возмущение.

$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i, i = 1, \dots, n$ – линейная регрессионная модель, β_0, β_1 параметры, которые необходимо оценить по выборке. $Y = \beta_0 + \beta_1 X$ – линия теоретической регрессии, а $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$ – линия выборочной регрессии.

RSS - Residual Sum of Squares. OLS((МНК) основан на минимизации RSS. Таким образом задача OLS сводится к следующему:

$$RSS(\hat{\beta}_0, \hat{\beta}_1) \rightarrow \min$$

Формулы для оценок OLS.

$$\hat{\beta}_1 = \frac{\sum X_i Y_i - n \bar{X} \bar{Y}}{\sum X_i^2 - n \bar{X}^2} = \frac{Cov(\hat{X}, Y)}{Var(\hat{X})}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Лекция 3. Линейная регрессия для одного параметра - дисперсионный анализ

Условия для линейной регрессии с константой

1. $\bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{X}$ - Линия регрессии проходит через \bar{X}, \bar{Y}
2. $\sum e_i = 0$ - Отсутствует систематическая ошибка
3. $\sum Y_i = \sum \bar{Y}_i$ - Сумма всех значений Y совпадает с суммой всех выровненных Y
4. $\bar{Y} = \hat{Y}$ - Среднее арифметическое по всем значениям Y совпадает со средним арифметическим по всем выровненным Y
5. $\sum X_i e_i = 0$ - Векторы X и e ортогональны
6. $\sum \hat{Y}_i e_i = 0$ - Векторы \hat{Y} и e ортогональны

Sums of squares

$\sum (Y_i - \bar{Y})^2 = TSS$ (Total sum of squares)

$\sum (\hat{Y}_i - \bar{Y})^2 = ESS$ (Explained sum of squares)

$\sum e_i^2 = RSS$ (Residual sum of squares)

TSS = RSS + ESS

$$R^2 = \frac{ESS}{TSS} = \frac{\sum (\hat{Y}_i - \bar{Y})^2}{\sum (Y_i - \bar{Y})^2} = \frac{Var(\hat{Y})}{Var(Y)} = \frac{TSS - RSS}{TSS}$$

R^2 является отношением ESS к TSS, (или долей дисперсии Y , объясненной с помощью регрессии). Очевидно, это неотрицательная величина.

Критерий лучшей оценки

Best – это оценки с наименьшей дисперсией в классе всех линейных несмещенных оценок.

$$\sigma_{\hat{\beta}_0}^2 = \sigma_\epsilon^2 \frac{\sum X_i^2}{n \sum x_i^2}, \sigma_{\hat{\beta}_1}^2 = \frac{\sigma_\epsilon^2}{\sum x_i^2}$$

Оценка дисперсии возмущений

$$\hat{\sigma}_\epsilon^2 = \frac{RSS}{n-2}$$

Является несмещенной оценкой дисперсии возмущений, а также стандартной оценкой регрессии в квадрате.

Лекция 4. Теорема Гаусса-Маркова, Классическая линейная регрессия

$$Y = \beta_0 + \beta_1 X + \epsilon$$

Теорема Гаусса - Маркова

Т.к X - детерминированный, а ϵ - случайный вектор, то $\hat{\beta}_1$ - случайная величина.

- 1) Если модель $Y = \beta_0 + \beta_1 X + \epsilon$ правильно специфицирована,
- 2) $X_i, i = 1, \dots, n$ детерминированы и не все равны между собой,
3. $E(\epsilon_i) = 0$
4. $Var(\epsilon_i) = \sigma_\epsilon^2$
5. $Cov(\epsilon_i, \epsilon_j) = 0$

То оценки МНК β_0, β_1 являются BLUE (Best Linear Unbiased Estimator)

ϵ - сумма влияния многих факторов, каждый из которых незначительно влияет на Y . По Центральной предельной теореме такая случайная величина имеет нормальное распределение.

Если $\epsilon_i, i = 1, \dots, n$ распределены нормально, то есть $\epsilon_i \sim N(0, \sigma_\epsilon^2)$, то оценки параметров β_0, β_1 тоже распределены нормально, причем $\beta_0 \sim N(\beta_0, \frac{\sum X_i^2}{n \sum x_i^2} \sigma_\epsilon^2)$, а $\beta_1 \sim N(\beta_1, \frac{\sigma_\epsilon^2}{\sum x_i^2})$, где $x_i = X_i - \bar{X}, i = 1, \dots, n$

Проверка гипотез теории

1. Выбора основной и альтернативной гипотезы,
2. Вычисления некоторой тестовой статистики,
3. Выбора уровня значимости α (числа между 0 и 1),
4. Самые распространенные уровни значимости 0.05 и 0.01,
5. Разбиения множества значений тестовой статистики на две области: там, где основная гипотеза отвергается и там, где основная гипотеза не отвергается

Пример

Модель: $Y = \beta_0 + \beta_1 X + \epsilon$

Нулевая гипотеза: $H_0 : \beta_1 = \beta_1^0$

Двусторонняя альтернативная гипотеза: $H_1 : \beta_1 \neq \beta_1^0$

1. Сначала необходимо оценить по n наблюдениям модель: $\hat{Y} = \beta_0 + \beta_1 X + \epsilon$

2. Если нулевая гипотеза не отвергается, то тестовая статистика $t = \frac{\hat{\beta}_1 - \beta_1^0}{s.e.(\hat{\beta}_1)} \sim t(n-2)$ имеет t - распределение с $n-2$ степенями свободы.
3. Гипотеза отвергается если: $|t| \geq t_{\alpha/2}^c r$
4. Если нулевая гипотеза отвергается, то говорят, что коэффициент значим. Если нулевая гипотеза не отвергается, то коэффициент называется незначимым
5. P - value – минимальный уровень значимости, при котором нулевая гипотеза отвергается. На рисунке это площадь всей заштрихованной области.
6. В таблице выделены P -value для проверки гипотез о значимости коэффициентов регрессии. Если P -value коэффициента регрессии меньше, чем выбранный уровень значимости, то нулевая гипотеза отвергается и соответствующий коэффициент является значимым. В приведенном примере при любом разумном уровне значимости константа незначима, а коэффициент наклона значим.

ДИ для оценок коэффициентов регрессии.

Найдем множество всех значений параметра β_1 , гипотеза о равенстве которым при заданном уровне значимости и двусторонней альтернативной гипотезе не отвергается.

Гипотеза $H_0 : \beta_1 = \beta_1^0$

$$t_c r = \frac{\hat{\beta}_1 - \beta_1^0}{s.e.(\hat{\beta}_1)} \sim t(n-2)$$

Следовательно формула ДИ для оценки коэффициента:

$$\hat{\beta}_1 - t_{\alpha/2}^{cr} s.e.(\hat{\beta}_1) \leq \beta_1^0 \leq \hat{\beta}_1 + t_{\alpha/2}^{cr} s.e.(\hat{\beta}_1)$$